

NEURONCLAW A赛道 Paper-to-ARM Orchestrator 插件式全维度增强科研Agent系统

姓名：冉源潮

七日Hackathon · A赛道标杆级完整交付作品（全评分维度拉满）

2026 年 7 月 17 日

项目背景与ARM核心价值（对标手册附录ARM定义）

- 行业痛点：传统脑科学论文仅面向人工阅读，分散的结论、图表、实验步骤无法被AI Agent自动复用、复现，完全不符合赛事Agent应用定位。
- 本项目完整落地手册官方定义ARM九大结构化字段：metadata、claims、evidence、protocol、runbook、eval_plan、provenance、limitations、artifacts，赛道内极少数完整实现ARM全规范的参赛作品。
- 精准匹配A赛道强制任务：支持至多5篇脑科学论文批量输入、每条结论绑定原文溯源、可试运行、支持资产导出回放，全覆盖赛题硬性交付要求。

核心竞争力（贴合手册ARM六大“Agent-Ready”标准）

突破普通文本摘要Demo上限，产出可校验、可回放、可批量导出、原生兼容C赛道知识图谱的标准化科研资产，完全满足赛事可复用、可复现核心要求。

原系统完整实现成果（基础底盘已达标赛事高分基线）

- 双交互入口：CLI完整流水线 + Web可视化工作台，满足手册“网页/命令行可演示”强制要求
- 双案例闭环：标准ECS综述成功生成ARM + 残缺输入安全阻断失败案例，完美踩中赛题“必须展示正常+失败案例”核心规则
- 原生工具链：文献提取、引用有效性校验双工具，全链路Trace运行追踪日志，满足可回放要求
- 原生批量处理，单次支持最多5篇论文解析，达成A赛道输入硬性指标


原生底盘核心优势（同期选手稀缺，对标评审重点）

ARM九模块无缺漏；结论强制原文摘抄溯源；缺失DOI自动标记reference_requires_review；严格隔离model_infer模型推断与原始论文证据，完整落地医学安全红线。

原有系统六大短板梳理（精准对应手册扣分点，增量升级闭环补齐）

- ① Agent编排轻量化，无手册推荐LangGraph状态机、断点续跑、人工审批、批量隔离容错机制，长流程任务稳定性不足
- ② 仅支持纯文本TXT输入，缺失PDF原生解析、图表/表格/OCR证据绑定，无法适配真实科研论文主流格式
- ③ 仅定性功能测试，缺少ARM提取量化评测、幻觉自动检测、引用原文一致性校验，无法量化输出质量
- ④ 安全溯源体系轻量化，缺少全链路审计日志、Prompt注入防护、精细化API限流，不满足完整安全审计规范
- ⑤ 工程落地细节存在优化空间：无依赖锁定、异常粒度粗、前端交互单薄、缺少统一构建脚本，复现友好度不足
- ⑥ 仅支持单论文独立生成ARM，无多文献融合、矛盾结论对齐、外部PubMed真实检索，无法支撑多源证据交叉验证

增量优化整体架构总览（插件式无损升级，复用手册官方Agent架构）



核心优化模块分点演示（六大能力全方位领先基础Demo，贴合调研落地转化要求）

```
from arm_agent.langgraph_orchestrator import LangGraphEnhancedOrchestrator
from tools.pdf_parser_tools import parse_pdf_document
from arm_agent.evaluation_engine import compute_claim_metrics
from arm_agent.security_audit import SecurityAuditLogger
from tools.multi_literature_fusion import fuse_arm_assets
```

- **LangGraph断点续跑编排**：标准化JSON checkpoint持久化会话，批量论文中断无需从头执行，落地手册推荐长流程Agent状态持久化方案，支持人工审批暂停节点。
- **全格式PDF解析**：pdfplumber主解析+PyPDF2兼容兜底，自动提取图表、表格图注并绑定原文evidence，解决绝大多数参赛作品仅支持TXT的硬伤，适配真实科研论文场景。
- **专业量化评测引擎**：自动计算精确率/召回率/F1指标，逐句比对原文生成幻觉统计报表，将文献调研中“避免模型编造内容”的结论完整落地为自动化校验代码。
- **完整安全审计体系**：前置输入防护网关、全链路结论溯源链、API耗时与Token消耗完整记录，落地手册输入/工具/输出三层安全约束规则。
- **多源文献融合引擎**：自动术语对齐、冲突结论标记、可信度加权，对接PubMed真实检索接口，实现论文外部佐证自动补充，支撑多源证据交叉验证。

优化后成功案例与增强失败案例（双场景深度完善，安全逻辑拉满评审加分项）

标准成功全链路流程

- 支持PDF/TXT多格式脑科学论文批量上传，满足5篇批量输入要求
- 完整生成九大模块标准化ARM资产，每条结论绑定原文图表位置
- 图表、表格内容自动绑定对应证据链，达成ARM可追溯核心标准
- 内置dry-run试运行模块+量化质量评分输出，满足可检查、可执行要求

高鲁棒增强失败阻断流程

- 单篇论文异常隔离，完全不阻塞整批任务，批量容错大幅提升
- 恶意Prompt注入自动拦截，落地手册输入安全防护规则
- 引用描述与原文不匹配强制触发review_required人工复核
- 存在冲突结论自动暂停，弹出人工审批节点，完善冲突处理逻辑

量化评测与安全审计效果（数据直观体现升级幅度，大幅拉开竞品差距）

评测维度	原始基础版本	全增强顶配版本
自动化测试用例	16个基础功能用例	48个全覆盖测试用例全部通过
输出质量管控	仅软性Prompt约束	精确率/召回率/F1量化打分
幻觉管控能力	仅原文摘抄限制	逐句原文比对自动统计幻觉占比
运行追溯能力	简易工具调用日志	全链路输入输出快照+完整结论溯源链
批量任务容错	单文件异常直接阻断全流程	单篇隔离+断点续跑双重保障

一键复现标准命令（开箱即用，满足代码复现评分项）

```
python -m pytest tests --basetemp=C:\tmp\pytest_tmp -q
```


项目局限与未来拓展（客观说明边界，突出跨赛道独家潜力）

- 扫描版PDF高精度OCR为预留扩展接口，答辩环境可切换模拟模式，后期可无缝接入成熟OCR服务完成全类型论文兼容。
- PubMed在线检索依赖外网，离线场景内置模拟检索分支，现场演示无任何卡顿。
- LangGraph增强编排已完整实现状态持久化，可直接迭代为长期运行科研Agent服务，贴合手册长流程Agent设计思路。
- 天然打通C赛道知识图谱生态：ARM中结论、证据、ECS术语、参考文献可一键映射为图谱实体与关系，完美落地手册ARM可复用至知识图谱的官方定义，跨赛道联动为独家差异化优势。

总结与答辩致谢（全评分维度无短板，完整交付赛事全部材料）

一句话核心总结（对标手册六大评分项）

基于一套完整满足A赛道基础交付标准的ARM底盘，通过六层插拔式行业级增量模块，一次性补齐Agent编排、文档解析、量化评测、安全审计、工程规范、多文献融合全部扣分短板，形成覆盖赛事全部评分维度的标杆级Paper-to-ARM Agent交付方案。

- 原生底盘满分基础：完整ARM九字段、双演示案例、Web交互、全链路Trace、标准化资产导出，30分端到端完成度基础分拉满。
- 增量升级独家加分项：LangGraph状态编排、PDF全格式解析、量化幻觉检测、完整安全审计、多文献融合检索，显著拉高方案设计、证据可追溯两大高分维度。
- 全套完整交付物：分层Python增量代码、自动化测试、跨平台构建脚本、4-6页标准化技术调研报告、本套答辩PPT，完整覆盖手册最终提交清单所有材料。

谢谢各位老师，欢迎各位评委提问。