

NEURONCLAW Paper-to-ARM Orchestrator 插件式全维度增强科研Agent系统

姓名：冉源潮

工程化开源级全维度科研Agent系统实现

2026 年 7 月 17 日

项目背景与ARM核心价值

- 行业痛点：当前许多科研Agent仅完成浅层文本摘要，分散结论、图表、实验链路不存在结构化绑定，无法供下游AI自动复用复现，难以达到工业级Agent落地标准。
- 全量实现方案：本项目完整落地ARM九大结构化字段：metadata、claims、evidence、protocol、runbook、eval_plan、provenance、limitations、artifacts，全字段无缺失，确保科研资产的结构化与完整性。
- 核心功能全覆盖：原生支持至多5篇脑科学论文批量输入、每条结论强制绑定原文溯源链路、内置Dry-run自动化试运行、标准化ARM资产导出与完整Trace回放，全面满足科研场景的严苛需求。

核心竞争力

彻底脱离普通大模型摘要Demo的能力下限，产出可校验、可回放、可批量导出、原生无缝兼容知识图谱的标准化科研资产；整体分层架构、插件化设计、自动化测试体系完全对标开源仓库工程规范，具备极高的开源分发潜力，完美契合可复用、可复现的核心标准。

原系统完整实现成果

- 双交互入口同步落地：CLI完整流水线搭配Web可视化工作台，两端均可独立完整演示，提供灵活便捷的操作体验。
- 正反双案例闭环设计：标准ECS综述完整生成ARM正向落地案例 + 残缺文献安全阻断失败容错案例，同时展示正常运行与异常阻断场景，逻辑严密完整。
- 原生配套两套专业工具链：文献全文深度提取工具、引用有效性自动校验工具，配套全链路Trace运行追踪日志，支持任务完整过程回放，可追溯能力极强。
- 原生批量并行架构，单次稳定承载5篇论文同步解析，满足批量输入需求，底层批量隔离逻辑提前规避单文件崩溃阻塞全局任务的缺陷。


原生底盘核心优势

ARM九大模块无缺漏落地；全部结论强制原文摘抄溯源，从根源杜绝无依据模型生成内容；缺失DOI条目自动标记reference_requires_review人工复核节点；严格区分模型推断文本与原始论文证据，完整落地医学科研数据安全红线；底层代码分层规范对标开源仓库标准，可直接开源交付。

原有系统六大短板梳理

- ❶ Agent调度能力单薄：未引入LangGraph状态机，缺失断点续跑、人工审批、批量隔离容错机制，多论文长流程任务稳定性不足，难以满足工业级开源项目标配的调度能力。
- ❷ 文档解析能力存在局限：仅兼容纯文本TXT输入，缺失PDF原生解析、图表/表格/OCR证据绑定模块，无法适配真实科研论文的主流格式，落地场景受限。
- ❸ 输出质量管控仅依靠定性约束：缺少ARM提取量化评测、幻觉自动检测、引用原文一致性自动化校验模块，无法量化输出可信度，缺乏成熟开源工程必备的自动化质量检测组件。
- ❹ 安全溯源体系轻量化：缺少全链路审计日志、Prompt注入防护、精细化API限流管控模块，无法达到完整安全审计交付规范，难以满足医学科研数据的安全约束要求。
- ❺ 工程落地细节待优化：无固定依赖锁定机制、异常捕获粒度粗放、前端交互功能单薄、缺少一键构建脚本，代码复现门槛较高，需进一步向开源仓库标准化交付规范靠拢。
- ❻ 仅支持单篇论文独立生成ARM资产，不存在多文献融合、矛盾结论自动对齐、外部PubMed真实检索联动能力，无法支撑多源证据交叉验证等高阶科研场景。

增量优化整体架构总览



核心优化模块分点演示

```
from arm_agent.langgraph_orchestrator import LangGraphEnhancedOrchestrator
from tools.pdf_parser_tools import parse_pdf_document
from arm_agent.evaluation_engine import compute_claim_metrics
from arm_agent.security_audit import SecurityAuditLogger
from tools.multi_literature_fusion import fuse_arm_assets
```

- **LangGraph断点续跑编排：** 标准化JSON checkpoint持久化会话，批量论文中途中断无需从头执行，原生落地长流程Agent状态持久化方案，支持人工审批暂停节点；保障长流程任务的极高稳定性。
- **全格式PDF解析插件：** pdfplumber主解析搭配PyPDF2兼容兜底双解析引擎，自动提取图表、表格图注并绑定原文evidence证据链，彻底解决传统系统仅支持TXT输入的局限，完美适配真实脑科学科研论文场景。
- **专业量化评测引擎：** 自动批量计算精确率/召回率/F1质量指标，逐句逐段比对原文生成幻觉统计报表，将文献调研中“杜绝模型编造无依据内容”的理论要求完整落地为可自动化运行的校验代码，提供稀缺的量化质控方案。
- **完整安全审计体系：** 前置输入恶意Prompt防护网关、全链路完整结论溯源链、API耗时与Token消耗全量记录归档，完整落地输入/工具/输出三层安全约束规则，安全规范对标开源仓库风控模块实现。

NEURONCLAW Paper-to-ARM 工作台落地界面实拍




Dry-run全项校验，无失败步骤




5篇论文批量结论自动提取



标准化ARM结构化JSON一键导出



论文图表证据自动绑定溯源链路



批量引用有效性自动校验与标记

优化后成功案例与增强失败案例

标准成功全链路流程

- 原生支持PDF/TXT双格式脑科学论文批量上传，稳定承载上限5篇并行任务，完全满足批量输入需求
- 完整生成ARM九大模块标准化科研资产，每一条结论强制绑定原文页码、图表坐标溯源位置
- 论文图表、附图、表格内容自动绑定对应证据链，完全达成ARM资产可追溯的核心标准
- 内置Dry-run全自动试运行模块搭配百分制量化质量评分输出，输出成果可随时校验、复现、审计

高鲁棒增强失败阻断流程

- 单篇论文异常完全隔离，崩溃文件不会阻塞整批任务执行，批量容错逻辑对标开源项目异常处理规范
- 恶意注入类Prompt自动拦截过滤，完整落地输入安全全维度防护规则
- 引用描述与原文文本不匹配自动触发review_required人工复核节点，杜绝不实证据入库
- 多文献间冲突结论自动暂停流程，弹出人工审批节点二次核验，完善高阶多源文献冲突处理逻辑

量化评测与安全审计效果

评测维度	原始基础版本	全增强开源级版本
自动化测试用例	16个基础功能用例	48个全覆盖专项测试用例全部通过
输出质量管控	仅软性Prompt文字约束	精确率/召回率/F1量化打分报表
幻觉管控能力	仅基础原文摘抄限制	逐句原文比对自动统计幻觉占比
运行追溯能力	简易工具调用日志	全链路输入输出快照+完整结论溯源链
批量任务容错	单文件异常直接阻断全流程	单篇隔离+断点续跑双重工业级保障

一键复现标准命令

```
python -m pytest tests --basetemp=C:\tmp\pytest_tmp -q
```

项目总结与致谢

项目核心总结

基于一套完整实现ARM九大字段的高稳定底盘，通过六层插拔式行业级增量增强模块，一次性补齐Agent调度编排、全格式文档解析、量化幻觉评测、全链路安全审计、标准化工程规范、多文献融合检索六大系统短板；整体模块化分层、自动化测试、安全风控体系完全对标开源仓库工业规范，是覆盖科研Agent核心能力维度的标杆级Paper-to-ARM完整交付方案。

- 原生底盘坚实基础：完整ARM九字段全实现、正反双演示案例、可视化Web工作台、全链路Trace回放、标准化资产一键导出，端到端完成度极高，夯实系统基础。
- 增量升级核心优势项：LangGraph状态持久化编排、PDF全格式图表解析、量化幻觉自动检测、完整安全审计链路、多文献PubMed融合检索，该五层高阶能力大幅提升了系统的方案设计深度与证据可追溯能力。
- 全套完整标准化交付物：分层解耦Python增量代码、全覆盖自动化测试套件、跨平台一键构建脚本、4-6页标准化技术调研报告、完整答辩PPT，全部覆盖标准提交材料要求，交付完备度极高。

谢谢各位老师，欢迎各位评委提问。